



Textkodierung und Textanalyse mit TEI, UE

Einführung in XML (Extensible Markup Language) & TEI (Text Encoding Initiative)





Regeln / Anwesenheit

- einfach drauflos reden und mich unterbrechen
- Feststellung der Anwesenheit (kurz mit Video wer mag)

Agenda, 23.10.2020

09:45 - 13:30

1.	Administratives und Organisation	09:45 - 10:30
	Theorie: XML & TEI und Beispielprojekte	
2.	Pause	10:30 - 10:45
3.	Wiederholung Screencast/Übung	10:45 - 11:30
4.	Pause	11:30 - 11:45
5.	XML-Schemasprachen: RELAX NG - Input	11:45 - 12:30
6.	Pause	12:30 - 12:45
7.	XML-Schemasprachen: RELAX NG 2 -Übung	12:45 - 13:15
8.	Ausgabe Assignment 1 & Fragen	13:15 - 13:30
9.	[Ersatz bzw früher Schluss für	
	Screencast/Übungen Vorarbeit]	13:30 - 14:45

Administratives und Organisation

Beurteilungskriterien

- Jede Teilleistung wird eigenständig bewertet.
- Vier praktische Übungsaufgaben/Assignments (80%) + Mitarbeit (20%).
 Mitarbeit in virtuellen Einheiten + auf Slack
- Maximal die Abwesenheit bei einem LV-Block erlaubt.

Aufwand: $5 \text{ ECTS} = 5 * 30 \text{h} \sim 150 \text{ Stunden}$

Termine

- Freitag 23.10.2020 09:45 -14:45 Digital
- Freitag 13.11.2020 09:45 -14:45 Digital
- Freitag 04.12.2020 09:45 -14:45 Digital
- Freitag 15.01.2021 09:45 -14:45 Digital

Digitale Kommunikation

Moodle - Materialien und Assignments

Slack - Arbeiten in Gruppen, Fragen an DozentInnen und "für alle"

Mail - Lehrende

1.Block: christopher.pollin@uni-graz.at

2.Block: roman.bleier@uni-graz.at

3.Block: hans.clausen@uni-graz.at

4.Block: <u>sarah.lang@uni-graz.at</u>

BBB - virtuelle Meetings

[im Notfall, wenn auch nicht erlaubt, Ausweichen auf Zoom]

Literatur

- Lou Burnard. What is the Text Encoding Initiative? How to add intelligent markup to digital resources. 2014. http://books.openedition.org/oep/426?lang=en.
- Lou Burnard. The Evolution of the Text Encoding Initiative: From Research Project to Research
 Infrastructure. Journal of the Text Encoding Initiative. Issue 5, 2013. http://journals.openedition.org/jtei/811.
- Marjorie Burghart und Elena Pierazzo. Digital Scholarly Editions: Manuscripts, Texts and TEI Encoding.
 DariahTeach. https://teach.dariah.eu/course/view.php?id=32.
- Susan Schreibman und Roman Bleier. Text encoding and the Text Encoding Initiative. DariahTeach. https://teach.dariah.eu/course/view.php?id=23.
- TEI (Hrsg.). TEI: P5 Guidelines. http://www.tei-c.org/Guidelines/P5/.
- Christian Weber. XML-Grundlagen, Ausarbeitung,
 http://wwwlgis.informatik.uni-kl.de/archiv/wwwdvs.informatik.uni-kl.de/courses/seminar/WS0203/ausarbeitung1.pdf

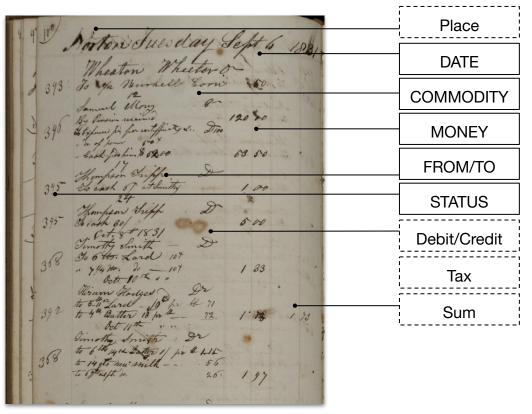
Moodle

- Georg Vogeler (et al.). XML. In: Digital Humanities. Fotis Jannidis, Hubertus Kohle und Malte Rehbein (Hrsg.).
 Stuttgart, 2017, 128-144.
- Patrick Sahle. Digitale Edition. In: Digital Humanities. Fotis Jannidis, Hubertus Kohle und Malte Rehbein (Hrsg.).
 Stuttgart, 2017, 234-249.

Theorie: XML & TEI und Beispielprojekte

die Idee hinter XML

- "Innerhalb von Dokumenten (Text) Tags vergeben können, um Komponenten Bedeutung zu geben"
- Tagset Notation = Paragraph
- Struktur im Dokument nutzen um...
 - zu verorten
 - zu adressieren
 - abzufragen
 - O ...



Wheaton Daybook, 1828-1859, USA

```
Wheaton Wheeter of 18181
```

```
<pb n="100"/>
<head>Norton <date ana="bk:when" when="1831-09-06">Tuesday Sept 6 1831</date></head>
<row ana="bk:entry" xml:id="T0">
    <cell ana="bk:status" corresp="#393">393</cell>
    <cell>
      <name ana="bk:from" ref="#pers WCDH118" type="person">Wheaton Wheeler</name>
      <span ana="bk:debit">Dr</span><lb/>To
      <measure ana="bk:commodity" commodity="corn"</pre>
             quantity="0.5" unit="bushels">1/2 Bushell Corn</measure></cell>
    <cell/>
    <cell>
      <measure ana="bk:money" quantity="50" unit="cents">50</measure></cell>
    <cell/>
    <cell/>
                                     Wheaton Daybook, digitalrepository.wheatoncollege.edu/handle/11040/17982,
                                           Data: https://gams.uni-graz.at/o:depcha.wheaton.1 gams/TEI SOURCE,
  </row>
                                                                                         11.09.2019
  [\ldots]
```

Beispiel: Romanistik/Sprachwissenschaft

http://gams.uni-graz.at/o:aaif.spapsh3/TEI SOURCE

```
<s>e dize maestre Pedro que este pujamiento
                                        dell aguaque fuera tanto en alto porque
tan
                                           <phr type="syntagm">tan
[a::alto::altos::apvmln]
                                             <w type="adverb" lemma="alto"</pre>
[v::subir::subieran::i]
                                             function="apvmln">altos</w>
[s::los fumos::mp]
                                             <w lemma="subir" function="i"</pre>
e los sacrificios
                                             type="verb">subieran</w>
                                             <w type="subject" function="mp">
                                             los fumos</w>
                                             de los sacrificios
    Morphosyntactic structure:
                        adjective
    Inflection:
                        masculine plural
                                           </phr>
    Attribution target
                        verb
                                           que los de Caím fizieran a los ídolos,
    Modified
                        ves
    Semantic Classification
                        location
                                           e que se lavasse de la suziedat
    Reduplication
                        no
                                           d'aquellos fumos ell aire.
                                        </s>
http://gams.uni-graz.at/context:aaif
```

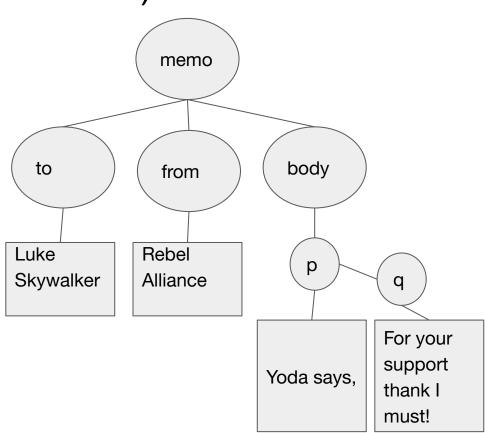
Beispiel: Literaturwissenschaft/Archiv

</msDesc>

```
<br/>
<biblFull xml:id="SZDBIB.1">
                                                                NACHLASS ▼ SAMMLUNGEN ▼ THEMEN ▼ BIOGRAPHIE INDEX ▼ GLOSSAR PROJEKT
                                                                                                                                 VOLLTEXTSUCHE
                                                                                                                                                       (1) DE | EN
▼ ⟨fileDesc⟩
  ▼ <titleStmt>
      (title)
        Der goldene Pfad : eine Botschaft der Liebe und Selk
                                                                                                        BIBLIOTHEK .
      (/title>
    ▶ <author ref="#SZDPER.821">
                                                                      A B C D E F
                                                                                           G
    </titleStmt>
    <publicationStmt>
                                                              Abraham, Pierre
      <publisher> Wiener Literarische Anstalt 
      <date precision="low"> 1921 </date>
                                                                ▼ Proust: recherches sur la création intellectuelle | 1930
      <pubPlace> Wien [et al.] </pubPlace>
    </publicationStmt>
                                                              Ambrosi, Gustinus
    <sourceDesc>
      <msDesc>
                                                                ▼ Einer Toten: ein Zyklus des Erinnerns | 1937
        <msIdentifier>
          <settlement> Salzburg </settlement>
                                                              Arens, Hanns
          <repository ref="http://d-nb.info/gnd/1047605287"</pre>
           <idno> SZ-BIB.KUR/GOLD1921 </idno>
                                                                ▼ Stefan Zweig: der Mensch im Werk | 1932
        </msIdentifier>
      ► <msContents>
                                                               ▼ Stefan Zweig: der Mensch im Werk | 1932
        <physDesc>
        ▶ <objectDesc>
        ▶ <additions>
        ▶ <bindingDesc>
        </physDesc>
        <history>
           ovenance>
             <orgName ref="szdg:LaterOwner" xml:lang="de"> Georg Rendinttp://elegt@hecale=de
             <orgName ref="szdg:LaterOwner" xml:lang="en"> Georg Rendl, St. Georgen (Stefan Zweig library provenance not verified!) /orgName>
          http://stefanzweig.digital/o:szd.bibliothek/TEI_SOURCE
        </history>
```

XML und Baumstruktur (→ XPath)

```
<?xml version="1.0"?>
<memo>
 <to>Luke Skywalker</to>
  <from>Rebel Alliance
 <body>
     Yoda says,
       <q>
       For your support thank
        I must!
       </q>
      </body>
</memo>
```



SGML - Standard Generalized Markup Language

A sample memo

To: Luke Skywalker

From: Rebel Alliance

Message:

Yoda says, "For your support thank I must!"

```
<MEMO>
 <TO>Luke Skywalker</TO>
 <FROM>Rebel Alliance
 <BODY>
      <P>Yoda says,
        <Q>
        "For your support thank
        I must!"
        </Q>
      </P>
    </BODY>
</MEMO>
```

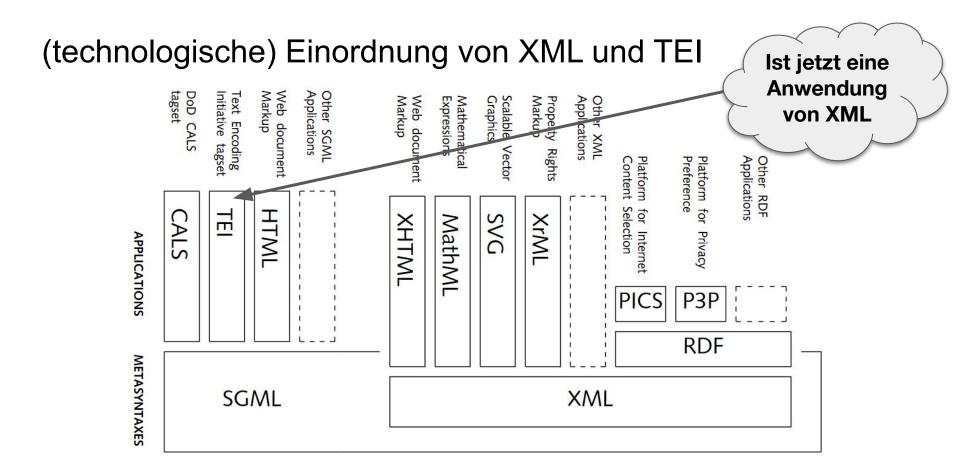


Diagram to show SGML/XML application and subset relationships.

TEI: de facto Standard für Text

"As a consequence, the TEI framework provides a useful way of thinking about the nature of text: it constitutes a kind of encyclopaedia of generally-agreed textual notions. In this brief guide we will try to exemplify some of these notions, using the vocabulary defined by the TEI in its Guidelines."

- ein (de facto) Standard
- eine gemeinsame Sprache
 "tagging by consensus"
- ein/mehrer Lösungswege "respect for diversity"
- eine Community und eine ein Framework
- ein Forschungsprojekt
- meist in XML umgesetzt (muss aber nicht); früher SGML
- ...

Wiederholung Screencast/Übung

Besprechung Übungen / Wiederholung

- Miriam [XML]
 - https://de.wikisource.org/wiki/Der Struwwelpeter/Die Geschichte vom Zappel-Philipp
- Thomas [XML]
 - https://de.wikisource.org/wiki/Der Struwwelpeter/Die Geschichte vom Suppen-Kaspar
- Birgit [TEI]
 - o https://de.wikisource.org/wiki/Der Struwwelpeter/Die Geschichte vom Zappel-Philipp
- Doris
 - o https://de.wikisource.org/wiki/Der Struwwelpeter/Die Geschichte vom fliegenden Robert

Überblick

Die Auszeichnungssprache - XML

XML-Editor Oxygen

De-facto-Standard innerhalb der GeWi - TEI



Ein Datenmodell zur Beschreibung von Memos

A sample memo

To: Luke Skywalker

From: Rebel Alliance

Message:

Yoda says, "For your support thank I must!"



Baumstruktur

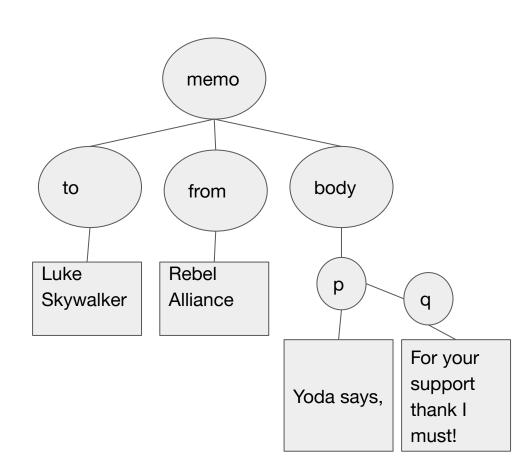
A sample memo

To: Luke Skywalker

From: Rebel Alliance

Message:

Yoda says, "For your support thank I must!"



Tag-Set-Notation und <Spitzklammern>

In information systems, a **tag** is a keyword or term assigned to a piece of information. This kind of metadata helps describe an item and allows it to be found again by browsing or searching.

[https://en.wikipedia.org/wiki/Tag (metadata)]

```
<P>Yoda says,

<Q>
    "For your support thank I must!"

</Q>

</P>
```



SGML - Standard Generalized Markup Language

A sample memo

To: Luke Skywalker

From: Rebel Alliance

Message:

Yoda says, "For your support thank I must!"

```
<MEMO>
 <TO>Luke Skywalker</TO>
 <FROM>Rebel Alliance
 <BODY>
      <P>Yoda says,
        <Q>
        "For your support thank
        I must!"
        </Q>
      </P>
    </BODY>
</MEMO>
```

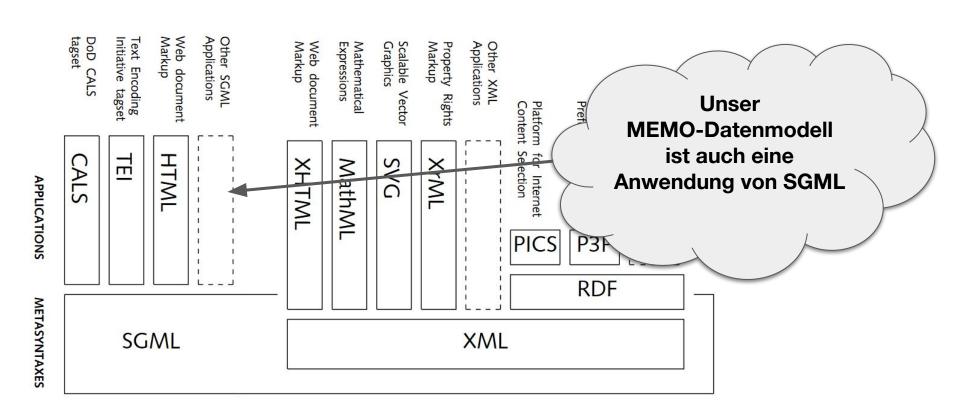


Diagram to show SGML/XML application and subset relationships.

XML - Extensible Markup Language

A sample memo

To: Luke Skywalker

From: Rebel Alliance

Message:

Yoda says, "For your support thank I must!"

XML wurde entwickelt um Daten zu **speichern** und zu **transportieren** und zwar so, dass sie **mensch- und maschinenlesbar** sind.

Extensible meint ... "erfinde Deine eigenen Elemente"

```
<?xml version="1.0"?>
<memo>
 <to>Luke Skywalker</to>
 <from>Rebel Alliance
 <body>
     Yoda says,
       "For your support thank
       I must!"
       </q>
     </body>
</memo>
```

XML - Extensible Markup Language

```
<?xml version="1.0"?>
<memo id="memo.1">
 <to>Luke Skywalker</to>
 <from>Rebel Alliance
 <body>
     Yoda says,
        <q>
        For your support thank
        I must!
        </q>
      </body>
</memo>
```

```
Elemente
```

<to>Ich bin Content</to>

Genau ein Wurzelelemente

<memo>...</memo>

Attribute

<memo id="memo.1">Content</memo>

Case-Sensitive: Groß-Kleinschreibung relevant

to-Luke-skywalker-//to-

Wohlgeformt (Syntax) - Valide (Schema)

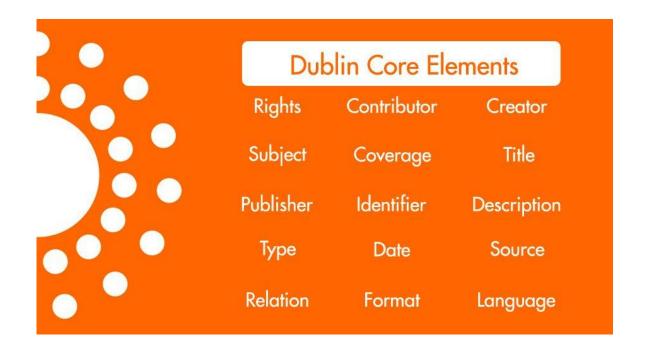
```
<?xml version="1.0"?>
<memo id="memo.1">
 <to>Luke Skywalker</to>
 <!-- ich bin ein Kommentar -->
 <from>Rebel Alliance
 <body>
     Yoda says,
       <q>
       "For your support
        & Courage thank
       I must!"
       </q>
     </body>
</memo>
```

Zeichen	Entity	Bedeutung
<	<	less than
>	>	greater than
&	&	ampersand
"	"	quotation mark
•	'	apostrophe

Tab. 4 Character Entities

XML...

- ... ist eine standardisierte, erweiterbare Auszeichnungssprache.
- ... ist eine plattformunabhängige, offene, nicht-proprietäre Metasprache mit deren Regel-Set Daten und Dokumente beschrieben werden.
- XML-basierte Dokumente sind menschen- und maschinenlesbar.
- ... basiert auf der Prämisse der strikten Trennung von (strukturiertem) Inhalt und Formatierung.
- XML-Daten sind damit unabhängig von einem Ausgabemedium (Single Source Publishing)
- … wird als Datenaustauschformat verwendet und dient als syntaktische Grundlage für Metadatenstandards.
- ... XML liefert Syntax Aufbau wird in einem Schema festgeschrieben!
- Schemasprachen (z.B.: Document Type Definition, XMLSchema) beschreiben Vokabular und Regeln



Spezifikation: https://www.dublincore.org/specifications/dublin-core/dcmi-terms/

Namespace: xmlns:dc="http://purl.org/dc/elements/1.1/"

Übung:

XML-Datenmodell zur Beschreibung einer Geschichte im Struwwelpeter

Suche dir eine Geschichte aus im *Struwwelpeter* https://de.wikisource.org/wiki/Der_Struwwelpeter

Überlege dir ein einfaches Modell, wie man diese Geschichten auszeichnen/strukturieren könnte.

- Die Tiefe und Komplexität sollte sich am "Memo"-Beispiel orientieren.
- Nutze den XML-Editor Oxygen dafür.
- Verwende nur maximal 5 unterschiedliche Elemente und 2 unterschiedliche Attribute.
- Verwende aber auch mindestens ein Element aus dem Dublin Core und binde den Namespace ein.
- Lade dein XML-Dokument auf Moodle hoch.
- Das XML muss wohlgeformt sein.







TEI - Text Encoding Initiative



Text Encoding Initiative - TEI

- Standard f
 ür die Textauszeichnung (insb. Sozial- und Geisteswissenschaften)
- zur Kodierung und dem Austausch von Texten, Urkunden, Sprachkorpora ...
- Module enthalten Elemente zur Modellierung und Auszeichnung

der Dokumentstruktur

von textkritischen Anmerkungen

von Handschriften, Gedichten und Wörterbüchern

...

TEI

http://www.tei-c.org

Spezifikation: https://tei-c.org/release/doc/tei-p5-doc/en/html/index.html

Struwwelpeter in XML/TEI

https://de.wikisource.org/wiki/Der Struwwelpeter/Die Geschichte vom b%C3%B6sen Friederich



Die Geschichte vom bösen Friederich.

Der Friederich, der Friederich,
Das war ein arger Wüterich!
Er fing die Fliegen in dem Haus
Und riß ihnen die Flügel aus.
Er schlug die Stühl' und Vögel tot,
Die Katzen litten große Not.
Und höre nur, wie bös er war:
Er peitschte seine Gretchen gar!

ju fich follo

, ber heulte febr, his immer mehr. im bas Bein,

[3]

Am Brunnen stand ein großer Hund,
Trank Wasser dort mit seinem Mund.
Da mit der Peitsch' herzu sich schlich
Der bitterböse Friederich;
Und schlug den Hund, der heulte sehr,
Und trat und schlug ihn immer mehr.
Da biß der Hund ihn in das Bein,
Recht tief bis in das Blut hinein.
Der bitterböse Friederich,
Der schrie und weinte bitterlich. —
Jedoch nach Hause lief der Hund
Und trug die Peitsche in dem Mund.

Comery an feinem Bein;

err Doltor fist babei hen bitt're Megenei.

[4]

Mis auch die gute Lebermurft Und trant den Wein für seinen Durft. Die Peitsche dat er mitgebracht Und nimmt fie sorglich sehr in acht. Ins Bett muß Friedrich nun hinein, Litt vielen Schmerz an seinem Bein; Und der Herr Doktor sitzt dabei Und gibt ihm bitt're Arzenei.

Der Hund an Friedrichs Tischchen saß, Wo er den großen Kuchen aß; Aß auch die gute Leberwurst Und trank den Wein für seinen Durst. Die Peitsche hat er mitgebracht Und nimmt sie sorglich sehr in acht.

[

Struwwelpeter in XML/TEI

MOODLE XML EXAMPLE

https://moodle.univie.ac.at/mod/resource/view.php?id=5616260

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xmlns="http://www.tei-c.org/ns/1.0">
   <teiHeader>
       <fileDesc>
           <titleStmt>
               <title>Review: an electronic transcription</title>
           </titleStmt>
           <publicationStmt>
               Published as an example for the Introduction module of TBE.
           </publicationStmt>
           <sourceDesc>
               No source: born digital.
           </sourceDesc>
       </fileDesc>
   </teiHeader>
   <text>
     <body>
       <head>Review</head>
       >
         <title>Die Leiden des jungen Werther</title>
         <note place="foot">by <name ref="http://d-nb.info/gnd/118540238">
           Goethe</name></note>
        is an <emph>exceptionally</emph> good example
        of a book full of <term ref="https://de.wikipedia.org/wiki/Weltschmerz">
        Weltschmerz</term>.
       </body>
    </text>
</TEI>
```

Metadaten

wo finde ich es, welche rechtliche Lizenz, was für ein Dateiformat....

Beschreibend ...

wer hat es verfasst, ID...

Technisch ...

hat 100kb, ist ein .txt, Prüfsumme...

Administrativ ...

Zugriffsrechte, Entstehung...

Strukturell ...

Vorder-, Rückseite...

Text + Annotation

Annotation ...

sagt etwas zu Aspekten des Objekts aus. Beschreibt den Inhalt.

"Watching": What is the Text Encoding Initiative? (Lou Burnard)



Übung:

TEI-Modell zur Beschreibung einer Geschichte im Struwwelpeter

Suche dir eine Geschichte aus im *Struwwelpeter (außer den bösen Friederich)* https://de.wikisource.org/wiki/Der Struwwelpeter

Überlege dir wie du diese Geschichte als XML/TEI Dokument beschreiben kannst. Befülle den teiHeader mit den Metadaten, beschriebe die äußere Struktur des Textes und füge einfache Annotationen hinzu. Unter einfachen Annotationen verstehen sich in dieser Übung die Auszeichnung von Namen, Orten, Datumsangaben oder anderen Begriffen, die dir wichtig erscheinen. Versuche diese Entitäten mittels Attribute zu normalisieren bzw. zu klassifizieren.

Nutze den XML-Editor Oxygen dafür und lade dein XML-Dokument auf Moodle hoch.

Das XML muss wohlgeformt und valide sein.



Struwwelpeter in XML/TEI

MOODLE XML EXAMPLE

https://moodle.univie.ac.at/mod/resource/view.php?id=5616260

XML - JSON (JavaScript Object Notation)

```
Übung:
{"book":
                                                    Bringen Sie ihr <book> XML nach JSON
    "author": "Abraham, Pierre",
    "title": "Proust : recherches sur la
          création intellectuelle",
    "publisher": "Rieder",
    "date": "1930",
                                                    XML nach JSON Converter
    "pubPlace": "Paris",
                                                    http://www.utilities-online.info/xmltojson/#.XEMJmS0o-Uk
    "series": "Maîtres des littératures ; 7",
    "settlement": "London",
                                                    JSON Validator
    "repository": "Erben Stefan Zweigs",
                                                    https://jsonlint.com
    "signature": "A.I.01",
    "language": "Französisch",
                                                    Mehr über JSON
                                                    https://www.w3schools.com/js/js json syntax.asp
    "measure": ["91, LX", "8°"]
```

Weitere Themengebiete zu XML

DTD, XML-Schema

Definition von eigenen Regelwerken | Metadatenstandards

Xpath - https://www.w3schools.com/xml/xpath_intro.asp

Navigation: "Gib mir alle Autoren, der Bücher aus dem Jahr 1930"

XSLT - https://www.w3schools.com/xml/xsl_intro.asp

Eine Programmiersprache zur Transformation von XML Daten.

"on-the-fly"

Analysen, Visualisierungen von XML-Dokumenten

XQuery - https://www.w3schools.com/xml/xquery_intro.asp

Abfragesprache von XML-Datenbanken, wie SQL für relationale Datenbanken.



https://docs.google.com/presentation/d/1uxDHXrYJDtgBn2v460P-P3GbCALaZh87KPfNTAdBymM/edit?usp=sharing